

投稿全文中文版（对照 docs/manuscript_JGG.md / submission_JGG.docx）

当数据泄漏被控制：基于 LLM 的 ACMG/AMP 变异分类多厂商可靠性审计

作者：宋兵¹、张凯^{2,*}（¹广州医科大学附属第三医院；²广东交通职业技术学院）

通讯作者：张凯 · zhangkai@gdcp.edu.cn

摘要（182 词）

背景：大语言模型（LLM）被越来越多地用于 ACMG/AMP 变异分类，但其训练语料包含 ClinVar 与 ClinGen，已报告的准确率可能反映的是对金标准标签的记忆而非真实推理。

目的：在受控标签泄漏（时间盲法）条件下，跨厂商、跨证据条件审计 LLM 变异分类的可靠性。

方法：在 5,000 个时间盲法 ClinVar 变异（全部于 2026 年 1 月后被专家评估）测试集上，我们评估了 6 个国产 LLM（30,000 次评估）与 3 个国际旗舰模型（Gemini 3 Flash、GPT-5.6-terra、Claude Sonnet 5，同一批 500 变异子集），并在 900 个专家评审变异上独立验证；子实验涵盖等位基因频率（AF）证据、冲突分类变异与 MaveDB 功能变异的消融。

结果：当代模型全对全准确率 61.8–71.6%，专家评审变异上达 86–93%。保守型模型表态时准确率 97.8–98.7%，而推理型仅 81.2–85.2%，且后者将良性变异误判为致病的假阳性率达 22–28%。提供 AF 使良性敏感度最多提升 57.8 个百分点。Gemini 国际领先（80.2%）；Claude 以 97.4% 表态准确率配 3.6% 假阳性。多数投票劣于最佳单模型。

结论：LLM 变异解读只有在“基于盲测证据选模型、证据完备（AF 必需）、弃权作为人工复核信号”三个条件下才可靠。

关键词：变异分类；ACMG/AMP；大语言模型；数据泄漏；ClinVar；可靠性审计；时间盲法

引言

临床变异解读——按 ACMG/AMP 指南将胚系变异判定为致病、良性或意义未明——是基因组医学的瓶颈：人工解读每变异耗费专家数小时，且实验室间判定不一致（Richards et al., 2015; Rehm et al., 2015）。大语言模型被提出作为可规模化的解读工具（Landrum et al., 2020; Karczewski et al., 2020; Cheng et al., 2023），近期更有工作报告接近专家水平的一致性（如 AI-CURA 报告在精选变异上达到专家级一致性）（AI-CURA, 2026）。

两个问题削弱了这些数字的可信度。第一，**训练数据泄漏**：LLM 语料包含公开变异数据库，模型被要求分类某变异时可能复述记忆的标签而非基于证据推理；已发表的评估极少控制这一

点。第二，**厂商依赖**：结果通常只在单一模型家族上报告，无法区分观察到的是 LLM 的共性还是某条训练管线的特性。

现有变异解读基准未能解决上述担忧：VariantBench（Basharat et al., 2025）评估 ACMG 分类与规则级论证但无泄漏控制；VarLitBench（Saadat and Fellay, 2026）锚定于 ClinGen 精选的功能证据，而这些证据的公开性使记忆成为可能；AI-CURA 在精选变异上展示了临床级表现，同样未控制模型训练时见过什么。在更广的 LLM 文献中，基准污染已被充分记录（Sainz et al., 2023; Bordt et al., 2024），时间分割评估也被提出作为去污染策略（Golchin and Surdeanu, 2023）。迄今没有研究将时间盲法、多厂商覆盖与独立专家评审验证在变异分类任务上大规模结合。

本文报告一项同时纳入这三重控制的审计：6 家厂商 6 个 LLM，在 5,000 个时间盲法 ClinVar 变异（全部于 2026 年 1 月后评估）上共 30,000 次评估，配 900 变异专家评审独立验证集与三个三角验证子实验（AF 消融、冲突解读变异、功能效应变异）。我们回答三个问题：

（RQ1）标签泄漏控制下 LLM 变异分类的可靠性如何？（RQ2）多模型共识与模型选择能否提升可靠性？（RQ3）可靠性如何依赖模型可获得的证据？

我们发现标签泄漏控制揭示了巨大的厂商差距（最高 +22 个百分点）；"模型表态即正确"的性质只对保守型模型成立；多数投票可能降低准确率；且模型可靠性与证据可得性同步——弃权是经过校准的可信信号而非噪声。我们将本工作定位为**可靠性审计**而非泛化研究：时间盲法消除了标签记忆通道，但先前的**证据**（文献、提交记录）可能仍在训练数据中；因此我们的目标是确立 LLM 输出在哪些操作条件下可信，而非宣称从序列到标签的原生泛化能力。

结果

队列与实验规模

我们在 5,000 个时间盲法 ClinVar 变异（全部 LastEvaluated ≥ 2026-01，即晚于所有受测模型训练截止）上评估了 4 家厂商 6 个 LLM（DeepSeek v4-pro/chat/coder、Kimi-K2.6、MiMo V2.5 Pro、Qwen3.7-max），共完成 29,996/30,000（99.99%）个"变异-模型"对；4 对（0.08%，Qwen 端点）永久失败并被排除。所有分析采用致病/良性二分类评估，VUS 视为弃权（见方法）。

表态的模型几乎总是正确的

我们报告两个互补指标：**全对全准确率**（VUS 计为错误；临床可用性视角）与**表态时条件准确率**（排除 VUS；表达意见的可靠性视角）。

表 1. 时间盲法测试集表现（n = 5,000 变异）

模型	厂商	全对全	表态准确率	表态数	专家评审档 (n=100)
Qwen3.7-max	阿里	71.6%	96.4%	3,714	86.0%
Kimi-K2.6	月之暗面	67.0%	97.8%	3,421	90.0%

MiMo V2.5 Pro	小米	66.1%	85.2%	3,876	92.0%
DeepSeek V4-pro	深度求索	61.8%	81.2%	3,806	93.0%
DeepSeek chat	深度求索	49.4%	98.6%	2,504	69.0%
DeepSeek coder	深度求索	49.2%	98.7%	2,494	68.0%
6 模型多数投票	—	64.1%	98.3%	2,915	93.5%

发现 1（代际差距）：当代旗舰（Qwen3.7-max、Kimi-K2.6、MiMo V2.5 Pro、DeepSeek V4-pro）比上一代（chat/coder）全对全高 **+12.6 至 +22.4 个百分点**（新旧代所有两两 McNemar 检验 $p \leq 2.9 \times 10^{-20}$ ；Kimi vs. MiMo: $p = 0.12$ ，不显著）。在最高可信度金标准（专家评审变异）上差距依旧（86–93% vs. 68–69%）。

发现 2（表态可靠性并非普遍成立——且错误方向至关重要）：保守型模型

（chat/coder/Kimi）表态时条件准确率 97.8–98.7%。相比之下，推理型（V4-pro 81.2%、MiMo 85.2%）表态更频繁（76–78% 变异）但表达的意见可靠性显著更低。关键的是错误方向不对称：金标准为良性的变异获得明确判定时，推理型更常直接判为**致病**——V4-pro 将全部良性变异的 28.4%、MiMo 22.3% 误标为致病，而 chat/coder 仅 1.3–1.4%、Kimi 2.5%；Qwen 居中（4.7%）。六模型共识将假阳性恢复到 1.8%。“模型表态即正确”**只对保守型成立**；对推理型，表态频繁、更不准确、且偏向临床危险方向（假致病）。

发现 3（多数投票可能有害）：六模型多数投票（64.1%）低于最佳单模型（Qwen 71.6%，差 7.5 个百分点），因为三张 DeepSeek 保守票主导了平票。模型**多样性与选择**比集成规模更重要；但当全体对某个明确判定一致时（2,915 个变异），条件准确率达 98.3%。

表面线索分层：多少成绩可以直接从变异名读出？

HGVS 蛋白记号本身可能暴露答案：单倍剂量不足基因背景下的无义（p.Xxx###Ter）与移码（fs）记号近乎致病诊断（类似 ACMG PVS1）。我们将金标准致病变异按变异名中有无此类功能丧失（LoF）表面线索分层。

模型	带线索 P 敏感度 (n=1,671)	无线索 (n=828)	差距
DeepSeek chat	98.5%	67.8%	−30.7 pp
Kimi-K2.6	99.8%	77.7%	−22.1 pp
Qwen3.7-max	99.5%	83.8%	−15.7 pp

发现 6（部分头条成绩是“读名”）：三分之二（1,671/2,499）的金标准致病变异名字中直接携带 LoF 线索，模型在其上全部接近天花板（98.5–99.8%）——这种成绩无需超出“识别记号”的基因疾病知识。在 828 个无线索变异（错义、同义、剪接区）上，敏感度降至 67.8–83.8%，仍远高于 50% 基率——模型保有真实判别力，但弱 16–31 个百分点。朴素准确率混淆了两种情形；可靠性审计应同时报告两个分层。Qwen 退化最小（−15.7 pp），与其整体领先一致。

独立金标准：ClinGen 专家评审

我们构建了 900 个专家评审变异的专用验证集（ClinGen 变异评审专家组/指南委员会；ReviewStatus = "reviewed by expert panel"；全部 ≥ 2026-04 评估；P 侧 645 = 致病 303 + 可能致病 342，B 侧 252 = 良性 59 + 可能良性 193，3 个复合 P/LP 标签列为不可评）。其中 100 个也

被抽入主测试集（表 1 专家评审档）；为保证独立性，表 2 报告 **800 个排他变异**（797 可评；P: 550, B: 247）。

表 2. 专家评审验证（n = 797 排他变异；3 模型）

模型	全对全	条件准确率
Kimi-K2.6	72.8%	90.6%
DeepSeek chat	42.9%	95.0%
DeepSeek coder	43.3%	94.8%

厂商差距在最强金标准上**扩大**（Kimi vs. chat +29.9 pp，一般测试集上为 +17.6 pp），说明模型选择对临床的影响比通用基准显示的更大。"全判致病"基线在该偏 P 集上得 69.0%；Kimi 的 72.8% 超过它，而 DeepSeek 的 ~43% 反映弃权损失而非误分类（条件准确率 94.8–95.0%）。

三角验证：证据可得性驱动可靠性

(a) 等位基因频率（AF）消融（n = 400×3 良性富集 + 150×2 致病）。向提示词加入人群等位频率（AF_ESP/ExAC/1000G，来自 ClinVar VCF）——同一批变异、同一模型、其余提示词完全相同——良性敏感度从 11.0% 升至 68.8%（chat, +57.8 pp）、10.7%→68.3%（coder）、43.4%→81.5%（Kimi）；chat 弃权率从 80% 降至 33%，全对全约增至三倍（chat 19.1%→66.5%；Kimi 49.3%→80.8%）。主实验观察到的系统性良性弃权主要是信息缺失行为，而非模型保守。该效应是双向的：在致病富集 AF 子集（n=150×2）上，加 AF 使准确率从 44.9%→64.0%（chat, +19.1 pp）、47.5%→85.3%（Kimi, +37.8 pp），弃权率从约 50% 降至 15–36%。证据完备性支配 P/B 两轴的可靠性。

(b) 冲突解读变异（n = 300×2）。在临床提交者意见相左的变异上，模型自发将弃权率提高 +22.5 pp（Kimi）与 +39.1 pp（chat）——尽管提示词不含任何冲突信息。LLM 表现出基于证据的不确定性校准：它们能感知争议。

(c) 功能效应任务（MaveDB, n = 300×2）。在具极端功能分数（功能丧失：≤ -0.8；正常：≥ 0.5）但无临床证据的深度突变扫描变异上，模型大规模弃权（73–93%），表态时方向一致率约为随机（45–55%）。LLM 不具备从蛋白序列原生推断功能效应的能力——而且它们自知（弃权而非幻觉）。

小结：证据可得——专家评审 86–93%；ClinVar 时间盲法 62–72%；无临床证据约 50% 条件一致 + 73–93% 弃权。

校准

平均自报置信度（0.73–0.80）与全对全准确率不匹配（chat 0.78 vs 49.4%；Kimi 0.73 vs 67.0%）。置信度在模型决策风格内部校准，跨模型则不成立；推理型相对其条件准确率过度表达置信度（V4-pro 0.79 vs 81.2%；MiMo 0.80 vs 85.2%）。

五分类分析："Likely"档缺失

ACMG/AMP 框架是五分类，P 与 LP 的临床随访不同（如 LP 需确认）。在带五分类标签的专家评审集（P 306、LP 342、LB 193、B 59）上，所有受测国内模型从未输出过 "Likely" 类——五分类输出坍塌为三分类（P/VUS/B）。

模型	精确五分类匹配	Likely 档输出	跨语义错误（P↔B）
Kimi-K2.6	32.3%	0/900	7.2%
DeepSeek chat	22.4%	0/900	2.1%
DeepSeek coder	22.7%	0/900	2.2%

强度极化是系统性的：金标准可能致病变异的 82%（Kimi）与 58%（chat）被升级为致病；可能良性的 51% 被 Kimi 降级为良性。两点含义：（i）LLM 输出仅在二分类语义层面可用——"Likely"档携带模型不产生的临床信息；（ii）二分类上报告的高条件准确率部分是 通过这种坍塌实现的。

输出确定性（可复现性审计）

临床系统必须对同一变异返回 相同答案，因此我们以完全相同设置（temperature = 0）重跑了 50 变异 × 3 模型并测量一致率。

表 S1. 重跑一致性（n = 50×3）

模型	精确类一致	二分类一致
DeepSeek chat	50/50（100.0%）	50/50（100.0%）
Kimi-K2.6	49/50（98.0%）	50/50（100.0%）
DeepSeek V4-pro	31/50（62.0%）	32/50（64.0%）

发现 4（推理模型不确定）：temperature = 0 下，对话型模型精确复现输出（100%），而推理型 V4-pro 在 36% 的重跑变异上改变了二分类判定——包括 3 次直接的良性↔致病翻转（临床后果最严重的错误方向）和 9 次 VUS↔明确类变化。在可靠性审计框架下，不确定性是一等失败模式：对相同输入可能返回矛盾答案的模型无论平均准确率如何都不能用于临床流程。"推理模型表态多但不可靠"（发现 2）于是延伸到表态稳定性。

成本审计

表 S2. 每变异 token 用量、成本与延迟（n = 30×6）

模型	输入 tok	输出 tok	成本（¥/变异）	延迟（秒）
DeepSeek chat	179	132	0.001	2.3
DeepSeek coder	179	137	0.001	2.5
Kimi-K2.6	183	160	0.003	5.9
DeepSeek V4-pro	179	2,728	0.017	65.9
Qwen3.7-max	206	1,936	0.019	37.7
MiMo V2.5 Pro	440	1,754	0.041	30.6

发现 5（推理税）：推理模型比对话型多产生 **13–21 倍输出 token**（思维链按补全计费），每变异成本跨度 **41 倍**、延迟跨度 **29 倍**。结合发现 2 与 4（表态更不准 + 不可复现），推理风格没有换来准确率、稳定性或安全性中的任何一项：除原始全对全外，对话型在所有维度占优，而 Kimi（67.0%）以 1/6–1/14 的成本匹敌或超过每个推理模型。对人群规模变异筛查，模型选择也是成本决策。

国际扩展：同一 500 变异子集上的三个外国旗舰

为检验国内发现是否跨训练生态成立，我们在同一时间盲法测试集的前 500 个变异上评估了 Gemini 3 Flash、GPT-5.6-terra 与 Claude Sonnet 5（相同提示词；三者统一加研究性 system prompt，见方法）。

表 S3. 同一 500 变异子集九模型对比

模型	厂商	全对全	条件	弃权	良性→致病 FP
Gemini 3 Flash	Google	80.2%	89.7%	10.6%	17.4%
Claude Sonnet 5	Anthropic	73.8%	97.4%	24.2%	3.6%
Qwen3.7-max	阿里	73.4%	96.1%	23.6%	5.7%
Kimi-K2.6	月之暗面	67.8%	98.0%	30.8%	2.8%
MiMo V2.5 Pro	小米	66.6%	86.9%	23.4%	19.4%
GPT-5.6-terra	OpenAI	63.4%	84.1%	24.6%	23.9%
DeepSeek V4-pro	深度求索	63.0%	84.0%	25.0%	24.3%
DeepSeek chat	深度求索	47.0%	98.3%	52.2%	1.6%
DeepSeek coder	深度求索	47.4%	98.3%	51.8%	1.6%

发现 7（国内发现国际成立——且更锐利）：（i）**Gemini 3 Flash 领先全部九模型**（80.2%，比最佳国内模型高 6.8 pp；McNemar $p = 1.5 \times 10^{-3}$ ）且弃权率最低——但代价是 17.4% 的良性假阳性，与 V4-pro（24.3%）、MiMo（19.4%）同属激进阵营。（ii）**Claude 表现如保守型模型**：97.4% 条件准确率、FP 3.6% [95% CI 1.9–6.8]——其假阳性率与 Kimi（2.8% [1.4–5.7]）统计不可区分，全对全与 Qwen 打平（McNemar $p = 1.0$ ）且高于 Kimi（ $p = 5 \times 10^{-4}$ ）。发现 2 的保守/激进二分法是模型行为属性而非厂商国籍属性。（iii）**GPT-5.6-terra 落后于外国同侪**（63.4%，显著低于 Qwen： $p = 1.2 \times 10^{-7}$ ）——能力既不随国籍也不随假定价格档流动，强化了审计的核心信息：模型选择必须基于实测盲测证据而非厂商声誉。

提示词不对称稳健性检验与外国模型确定性

三个外国模型收到了国内模型没有的研究性 system prompt，我们做了两项检验。

- (a) 提示词对国内模型的效应（ $n = 100 \times 2$ ，同一变异）。向 Kimi 与 Qwen 加入同一 system prompt 后，全对全变化 -3 pp（Kimi 73→70%）与 -1 pp（Qwen 73→72%），弃权变化 ≤ 3 pp——轻微向保守偏移，远小于外国模型彼此间的行为差异（弃权 Gemini 10.6% vs Claude 24.2%；FP 17.4% vs 3.6%）。保守/激进归属因此不是提示词不对称的伪影。
- (b) 外国模型确定性（ $n = 20 \times 3$ ，temperature 0）。与原运行的精确类一致率：Gemini 80%、GPT 85%、Claude 75%；二分类一致 95%/85%/80%。外国模型介于完全确定的对话型（100%）与 V4-pro（64%）之间；中转路由可能贡献额外不确定性。方向上，发现 4 国际成立：推理级旗舰在 temperature 0 下输出不稳定。

讨论

主要发现

标签泄漏控制（金标准标签时间盲法）下，当代 LLM 全对全正确率 62–72%，专家评审变异上升至 86–93%。保守型模型表态时 97.8–98.7% 正确，仅将 1.3–2.5% 的良性变异误标为致病；推理型则误标 22–28%——临床危险方向。国际扩展（Gemini/GPT/Claude 于同一 500 子集）使 Gemini 总体第一（80.2%）并显示保守/激进二分法跨生态成立。这些数字显著低于未盲法报告的专家级一致性（AI-CURA, 2026）；作为可靠性审计，它们界定的是 LLM 输出可信的**操作包络**而非泛化上限：标签记忆已受控，余下表现反映模型实际推理所用的证据。

厂商选择比集成规模更重要

最佳与最差模型差距（+22.4 pp 全对全；专家评审 +25 pp）超过我们测试的任何集成策略收益，且朴素多数投票**降低了**准确率（保守票主导平票）。两点含义：（i）不含模型身份的“LLM 准确率”没有意义；（ii）临床部署应基于盲测基准选择模型而非集成数量。推荐是模型特定的——Kimi 与 Qwen 在证据充足变异上出色；推理型（V4-pro、MiMo）表态更多但更不可靠。国际扩展（见上文）使之更锐利：Gemini 全对全领先但 17.4% 假阳性（激进阵营），Claude 以 97.4% 条件准确率配 3.6% FP（保守阵营，风格与 Kimi 一致）。行为风格——而非厂商、国籍或价格档——才是有效的选择标准。

弃权是校准行为而非保守

三个独立实验收敛：证据缺失时模型更多弃权（AF 消融：提供频率后弃权 80%→33%）；专家分歧时（冲突变异：未被告知却 +22–39 pp）；任务完全无临床证据时（MaveDB：73–93%）。LLM 表现得像证据感知的决策系统：证据弱处表达不确定，证据强处表态。临床上这使弃权成为**可信的分诊信号**——“模型说不确定，因此由人复核”是安全策略，且我们的数据显示模型恰在需要人工复核处不成比例地不确定。

可复现性作为可靠性属性

temperature 0 下对话型完全可复现（50 次重跑 100%），推理型 V4-pro 在 36% 重跑变异上改变二分类判定，包括良性↔致病翻转。仅平均准确率不足以审计临床可用性：不确定模型无论均值如何都不可部署，其单次报告准确率本身也是有噪声的。审计框架使之显式：确定性与准确率、弃权校准一样，是逐模型测量并报告的属性。

良性表现不佳的信息缺失解释

最引人注目的基线结果——良性敏感度 9.6–43%——很大程度由等位频率证据缺失解释。提供 AF 后良性敏感度最多 +57.8 pp，全对全约三倍。ACMG 的 BA1/BS1（人群频率）是最强良性证据之一；缺失它们使分类的良性侧瘫痪。实践含义：任何基于 LLM 的变异解读管线必须接入人群频率数据库；无 AF 报告的性能数字系统性低估良性召回。

与已有工作的关系

AI-CURA (AI-CURA, 2026) 展示了无泄漏控制的专家一致性；我们的标签盲测数字 (62–72%) 提示未盲法表现的相当部分可能是标签记忆。VariantBench (Basharat et al., 2025) 与 VarLitBench (Saadat and Fellay, 2026) 推进了评估严谨性——分别针对论证与 ClinGen 锚定证据——但都未对金标准做时间盲法也未跨厂商；我们补齐两者加独立专家评审验证。我们的条件准确率框架 (表态 vs. 弃权) 调和了既往报告中"自信时惊艳"与"整体不可用"的观察。定位：AI-CURA 问"LLM 能否分类变异"，我们问"在哪些可审计条件下 LLM 的分类可信"——审计框架使我们的主张严格限于时间盲法所能确立的范围。

局限

(i) 外国模型在 500 变异子集 (国内 5,000) 上经中转端点评估，并收到国内模型未收到的研究性 system prompt (为避免 Claude 医疗安全拒答所必需)；跨国比较因此是指示性而非决定性的，尽管子集对九模型完全相同。(ii) 时间盲法经 LastEvaluated 日期近似泄漏控制；变异的证据 (提交、文献) 可能早于标签，模型可能见过证据而非最终标签。(iii) 二分类 P/B 评估坍塌了 ACMG 五类并惩罚"Likely"映射策略。(iv) MaveDB 功能方向是软验证。(v) 单任务 (胚系 SNV/indel)；剪接/结构/新生变异未涉及。(vi) 成本审计 (30 变异 × 6 模型，API 报告用量)：推理模型多产生 13–21 倍输出 token (思维链接补全计费)，每变异成本跨度 41 倍 (MiMo ¥0.041 vs chat ¥0.001)、延迟跨度 29 倍 (65.9 s vs 2.3 s)——却未换来准确率、稳定性或安全 (22–28% 良性→致病假阳性)。(vii) 变异按基因聚集 (2,050 唯一基因)；独立性假设检验乐观——已并报基因层自助法置信区间且全部结论保持。(viii) HGVS 名中无义/移码记号可部分解释致病检测性能；我们分列了带/无线索分层。(ix) MaveDB 功能任务非时间盲法 (DMS 数据集 2019–2025 可能出现在训练语料)；即便可能已见过仍失败，强化而非弱化无原生推断的结论，但注意此保留。

结论

标签泄漏控制下，LLM 变异解读在三条件下通过可靠性审计：模型基于盲测证据选择 (厂商差距至 +22 pp；多数投票可能有害)、证据完备 (AF 必需；+58 pp 良性敏感度)、弃权作为人工复核触发。我们提供一项多厂商、时间受控、独立验证的可靠性审计，并建议：(i) 发表的准确率应报告模型身份、盲法状态与证据条件；(ii) 临床试点采用"致病自动标记、不确定自动升级"的运行策略；(iii) 未来审计扩展至更多国外厂商与任务类型。

材料与方法

数据来源

- ClinVar variant_summary (2026 年 8 月版；9,029,235 行；43 列)——测试集构建与金标准标签。

- ClinVar VCF (GRCh38) (~193 MB)——按 ALLELEID 附着 AF_ESP/AF_EXAC/AF_TGP。

- **MaveDB** (Ensembl 映射版: 3,158,202 个打分变异) ——功能三角验证; 基因符号经 mygene.info 解析。

- 数据全部公开; 下载地址见数据可用性。

时间盲法测试集 (标签泄漏控制)

核心设计决策: LLM 训练语料包含 ClinVar 历史, 评估必须使用**金标准标签**产于模型训练截止之后的变异。这专门控制标签记忆通道; 先前的 *证据* (文献、提交) 可能仍在训练数据中, 故我们将研究定位为受控标签泄漏下的可靠性审计而非泛化测试 (见讨论)。

- 模型截止 (2026-08 核实): DeepSeek V4 约 2025-12; 其余家族 ≤ 2025 。保守要求 **LastEvaluated $\geq 2026-01-01$** 。

- 入选: 明确临床分类 (仅致病/良性; 复合词排除于 P/B 金标准)、具 HGVS 名、无冲突分类。

- 按 ALLELEID 去重 (原始行 4.9% 为重复等位条目)。

- 分层采样: 致病 2,500 + 良性 2,500, 种子 42 (可复现), 得 $n = 5,000$ 。

- 结果: 5,000 变异最后评估于 2026-01 至 2026-07 (1 月 2,097 / 2 月 1,672 / 3 月 324 / 4 月 412 / 5 月 263 / 6 月 199 / 7 月 33), 即均晚于全部受测模型训练截止。

金标准

- **主金标准**: ClinVar 汇总分类 (P/B 二分)。

- **金标准 A (严)**: ReviewStatus $\in$ {reviewed by expert panel, practice guideline} —— ClinGen 专家组/指南委员会产出。专用验证集 900 个 (构成见结果); 其中 100 个与主集重叠 (表 1 专家档), 故专用集分析报告 800 排他 (797 可评), 900 全集作稳健性检验。

- **三角集**: 冲突解读变异 (44,815 候选, 采样 300); MaveDB 功能极端 (LoF 150: ≤ -0.8 ; 正常 150: ≥ 0.5)。

模型

六个国内模型先验选取为当代广泛使用的中国商业 LLM (上一代 DeepSeek 作厂商内代际对照)。国际覆盖另在同一测试集前 500 变异上评估三个外国旗舰 (同变异同提示词): **Gemini 3 Flash**、**GPT-5.6-terra**、**Claude Sonnet 5**, 经 OpenAI 兼容中转端点 (temperature 0, max_tokens 16,384)。因 Claude 试点拒答 25% (医疗安全策略), 三个外国模型统一收到确立研究基准语境的 system prompt; 此后拒答降至 0%。国内模型无 system prompt; 该不对称作为局限披露。

提示词设计

每变异以临床遗传学家任务呈现：变异名（HGVS）、基因符号、基因组坐标、HGVS cDNA/蛋白（可得时）及 AF 条件下的人群频率。要求返回严格 JSON：{五类分类、acmg_rules、confidence $\in [0,1]$ 、evidence_summary、references}。提示词**不含** ClinVar 意义标签、评审状态或冲突提示。宽松解析（围栏 JSON、单引号、尾随散文）；不可解析/空输出记为解析失败并计入全对全错误（等同弃权）；比率：V4-pro 0.60%（26 空 4 截断）、MiMo 0.10%（含 3 次端点内容过滤拒绝）、Kimi/Qwen $\leq 0.08\%$ 。

评估指标

- **全对全准确率**：P/B 二分匹配，VUS（及不可解析）计错——临床可用性视角。
- **条件准确率**：仅限明确表态（P 或 B）——意见可靠性视角。
- **弃权率**：VUS 输出占比。
- **混淆矩阵**与逐模型敏感度/特异度。
- **共识**：P/B/VUS 三分类语义多数投票；语义相近类（P vs LP）不分票；平票排除（另行报告）。
- **统计**：全部准确率的 Wilson 95% CI；共享变异集上模型比较用 McNemar 配对检验（ $n > 30$ 正态近似含连续校正）；变异按基因聚集（2,050 基因，3,952 变异在多变异基因，最大 NF1 83），另计算基因层聚类自助法 95% CI（1,000 次重采样）；约宽 1.5 倍而不改变任何结论。确定性以 50 变异 $\times$ 3 模型重跑（temperature 0）检验。

子实验

1. **AF 消融**（ $n = 400 \times 3 + 150 \times 2$ ）：同变异/模型/提示词，有/无等位频率块。
2. **冲突变异**（ $n = 300 \times 2$ ）：同一流程于冲突分类变异；构造上无金标准——分析弃权行为与判定分布。
3. **MaveDB 功能任务**（ $n = 300 \times 2$ ）：模型判定（P vs B）与实验功能方向（LoF vs 正常）的方向一致性，变异无临床证据。MaveDB 含每变异重复行；样本含 286 唯一变异（14 重复行），去重后所有统计不变。

可复现性

全部脚本、提示词、种子与中间文件公开（见数据可用性）；采样固定种子 42；全部 API 调用 temperature 0。分析代码：Python 3 标准库（无 ML 依赖）。

局限

见讨论"局限"节（i-ix）。

伦理声明

本研究仅使用公开数据库记录（ClinVar、ClinGen 衍生评审状态、MaveDB）。无人类受试者、患者材料或个人数据；无需机构审查委员会批准。

数据可用性

全部源数据公开可得：ClinVar variant_summary 与 VCF（<ftp.ncbi.nlm.nih.gov/pub/clinvar/>）、MaveDB Ensembl 映射版（ftp.ensembl.org/pub/current_variation/MaveDB/）、mygene.info。时间盲法测试集、金标准、全部 31,500 条原始模型输出与分析脚本见 <https://github.com/zksdu/llm-variant-reliability-audit>（Zenodo 存档，DOI: 10.5281/zenodo.21964620）。

代码可用性

自定义分析代码见 <https://github.com/zksdu/llm-variant-reliability-audit>（Zenodo 存档，DOI: 10.5281/zenodo.21964620）。管线仅用 Python 3 标准库；种子 42 下采样逐字节可复现。

CRedit 作者贡献声明

宋兵：概念化、调查、数据管理、验证、初稿撰写。

张凯：方法论、软件、形式分析、可视化、指导、审阅与编辑。全体作者阅读并批准了最终稿。

利益冲突

作者声明无利益冲突。

致谢

不适用。

参考文献

（17 条英文文献，与英文版一致，此处从略——见 manuscript_JGG.md References 节）

图注

图 1. 时间盲法测试集上的多模型表现。A：六个国内模型双口径准确率（n=5,000/模型）。B：同一 500 变异子集上九模型双口径（灰色为国际模型）。C：良性→致病假阳性率（对数轴，500 子集）；六模型共识值已标注。

图 2. 证据可得性支配可靠性。A: AF 消融（良性富集子集 $n=400 \times 3$ ）的良性敏感度。B: 致病富集子集（ $n=150 \times 2$ ）。C: 跨证据情境的弃权率（有无 AF、主集 vs 冲突、MaveDB）。

图 3. 输出确定性与 "Likely" 档坍塌。A: temperature 0 重跑一致率（含国际扩展）。B: 金标准可能致病/可能良性的输出分布（Kimi, 专家集）。

图 4. 成本-准确率权衡。每变异成本（对数轴）vs 全对全；气泡大小为延迟。

补充材料

- 表 S1 重跑一致性（ $n=50 \times 3$ ）

- 表 S2 每变异 token 用量、成本、延迟（ $n=30 \times 6$ ）

- 表 S3 同一 500 子集九模型对比

附录：文章图片




图 1. 时间盲法测试集上的多模型表现。A：六个国内模型双口径准确率（n=5,000/模型）；B：同一 500 变异子集上九模型对比（灰色为国际模型）；C：良性→致病假阳性率（对数轴），虚线为六模型共识 1.8%。




图 2. 证据可得性支配可靠性。A：AF 消融（良性富集子集 $n=400 \times 3$ ）的良性敏感度；B：致病富集子集（ $n=150 \times 2$ ）；C：跨证据情境的弃权率（有无 AF、主集 vs 冲突变异、MaveDB 功能任务）。




图 3. 输出确定性与 "Likely" 档坍塌。A: temperature 0 下重跑一致率（浅色为国际模型）；B: 金标准可能致病/可能良性变异的输出分布（Kimi, 专家集）——强度信息极化为全致病或全良性。




图 4. 成本-准确率权衡。每变异成本（对数轴）vs 全对全准确率；气泡大小为延迟。推理型模型（紫）占据贵且慢象限却无准确率或安全性收益。